



SYSTÈME DE RECOMMANDATION PROACTIF ONCF

Prédiction de trajets pour l'application mobile

STATUT DU PROJET : Phase Analyse & Architecture
DATE DE MISE À JOUR : 04 Avril 2026
PROPRIÉTAIRE : Omar Chekroun
DOMAINE : Data Science & ML Engineering

Table des matières

1	Contexte et Objectifs du Projet	2
2	Benchmark Stratégique : Systèmes de Prédiction	3
2.1	UBER – Destination Prediction (Prédiction Pré-saisie)	3
2.2	TRAINLINE / DEUTSCHE BAHN – Recommandation Ferroviaire	4
2.3	AIRBNB – Search Ranking (Optimisation de la Conversion)	4
2.4	GOOGLE MAPS – Commute Predictions (Proactivité & UX)	5
3	Synthèse du Benchmark	5
4	Stratégie de Collecte de Données	5
5	Architecture ML et Recommandations Techniques	6
5.1	Cadrage du Problème : Learning to Rank en Deux Étapes	6
5.2	Le Choix du Modèle : XGBoost (Gradient Boosted Trees)	6
5.3	Architecture de Déploiement	7
5.4	Gestion du Model Drift	7
6	Conformité Légale et Protection des Données	7
7	Faisabilité et Prochaines Étapes	8
7.1	Réalisabilité :	8
7.2	Métrique de Succès Prioritaire et Décision :	8

1. Contexte et Objectifs du Projet

Problématique : Actuellement, les utilisateurs de l'application ONCF Voyages ayant des habitudes de trajet répétitives doivent manuellement rechercher leur itinéraire à chaque ouverture de l'application. Ce processus réactif génère de la friction et allonge significativement le temps de réservation.

Objectif Principal : Développer un **système de recommandation proactif** prédisant le trajet de l'utilisateur et l'affichant dès l'écran d'accueil ("Zero-Click Search").

Impacts Métier Attendus :

- **Temps :** Réduction significative du temps de réservation grâce à la suppression des étapes de recherche manuelle.
- **Conversion :** Augmentation du taux de conversion (moins d'étapes = moins d'abandons).
- **Revenus :** Hausse des revenus par utilisateur via des réservations plus fluides.

2. Benchmark Stratégique : Systèmes de Prédiction

2.1. UBER – Destination Prediction (Prédiction Pré-saisie)

Contexte & Stratégie de Données

Uber

Uber s'est fixé pour objectif de supprimer l'étape de saisie de la destination. Dès l'ouverture de l'application, l'algorithme prédit où l'utilisateur souhaite aller, en se basant sur la récurrence temporelle et spatiale. C'est l'équivalent exact du "Zero-Click Search" visé par l'ONCF.

Pertinence ONCF : ★★★★★

Modèles & Features :

- Transition de modèles Bayésiens simples vers des réseaux **LSTM** (Long Short-Term Memory) et **XGBoost**.
- **Features clés :** L'heure exacte de la journée, le jour de la semaine, les coordonnées GPS actuelles (utilisées en temps réel pour identifier la gare de départ la plus proche, sans stockage en base), et l'historique des 10 derniers trajets.
- **Approche en deux étapes :** Uber génère d'abord un pool restreint de destinations candidates (Candidate Generation), puis utilise XGBoost pour *ranker* ces candidats et afficher le Top-1.

REX pour l'ONCF :

- **Trigger temporel :** L'heure d'ouverture de l'app ONCF est la variable prédictive numéro 1. Un utilisateur ouvrant l'app le vendredi à 17h00 a une intention très différente de celui l'ouvrant le mardi à 07h00.
- **Fallback local :** En cas de "Cold Start" (nouvel utilisateur), exploiter la localisation GPS transmise en temps réel par l'application (déjà disponible côté client) pour identifier la gare la plus proche et suggérer les trajets les plus populaires au départ de cette gare (ex : suggérer Casa-Voyageurs → Rabat-Ville si géolocalisé à Casablanca). *La localisation est utilisée uniquement en mémoire lors de la requête et n'est jamais persistée en base de données.*

2.2. TRAINLINE / DEUTSCHE BAHN – Recommandation Ferroviaire

Contexte & Stratégie de Données



Ces acteurs majeurs du secteur ferroviaire font face aux mêmes contraintes métier que l'ONCF. Leurs applications mettent en avant des "Quick-buy buttons" (boutons d'achat rapide) pour les trajets favoris dès l'écran d'accueil, ciblant spécifiquement les "commuters" (navetteurs).

Pertinence ONCF : ★★★★★

Modèles & Features :

- **Systèmes Hybrides :** Filtrage collaboratif léger + **Moteur de Règles Métier (Business Rules)** très strict.
- **Features clés :** Fréquence de la paire Origine/Destination, détention d'une carte d'abonnement (Navette, Navette Étudiant), état du trafic en temps réel.

REX pour l'ONCF :

- **Segmentation algorithmique :** Il faut distinguer le modèle prédictif des "Navetteurs" (trajets quotidiens très prévisibles) de celui des voyageurs "Occasionnels" (étudiants le week-end, vacances estivales).
- **Filtre de Réalité (Hard constraints) :** La prédiction ML doit passer par une API temps réel avant affichage pour bloquer la recommandation d'un train s'il est *complet* ou *annulé*.

2.3. AIRBNB – Search Ranking (Optimisation de la Conversion)

Contexte & Stratégie de Données



Airbnb a redessiné son moteur de recherche non pas pour générer des clics, mais pour maximiser les réservations réelles. Ils gèrent un environnement de recherche très structuré (dates précises, nombre de voyageurs, contraintes de prix), similaire à la sélection d'un billet de train.

Pertinence ONCF : ★★★★★

Modèles & Features :

- Utilisation massive des **Gradient Boosted Decision Trees (GBDT)** couplés à des **Embeddings** (représentations vectorielles des utilisateurs et des logements).
- **Features clés :** Écart entre le prix affiché et le budget moyen de l'utilisateur, délai avant le voyage (advance booking), durée du séjour.
- **Architecture Ranking :** Airbnb *rank*e un ensemble de candidats pré-filtrés via GBDT pour maximiser la probabilité de conversion.

REX pour l'ONCF :

- **Pondération des signaux :** Le modèle de l'ONCF doit accorder un poids écrasant à l'historique de *booking* (billets payés) par rapport aux simples recherches abandonnées.
- **Sensibilité au prix :** GBDT est excellent pour modéliser la tolérance au prix. Si l'utilisateur prend toujours la 2ème classe, le modèle ne doit proposer la 1ère classe que si l'écart de prix est exceptionnellement faible.

2.4. GOOGLE MAPS – Commute Predictions (Proactivité & UX)

Contexte & Stratégie de Données



Google Maps anticipe les déplacements quotidiens (Domicile-Travail) et envoie des notifications push proactives sur le trafic estimé, avant même que l'utilisateur n'ait sollicité l'application. L'enjeu principal ici est l'acceptation par l'utilisateur (UX) d'un système qui "devine" ses intentions.

Pertinence ONCF : ★★★★★

Modèles & Features :

- **Modèles Probabilistes** basés sur les chaînes de Markov et analyse fréquentielle pour identifier les gares d'attache et les habitudes horaires à partir de l'historique de réservations.
- **Features clés :** Régularité de la routine (gare de départ la plus fréquente, créneaux horaires récurrents), contexte calendaire (jours fériés).

REX pour l'ONCF :

- **Gestion du Seuil de Confiance (Thresholding) :** L'UX est cruciale. Le modèle va générer une probabilité (ex : 85% de chance que Alice aille à Rabat). Un seuil initial de 70% est envisagé pour décider de l'affichage du bloc proactif : en dessous, le système affiche la barre de recherche standard. *Ce seuil sera optimisé par rapport à un compromis précision vs. couverture mesuré lors de l'évaluation offline du modèle.*
- **Adaptation au Calendrier :** Le modèle doit intégrer les jours fériés marocains et les vacances scolaires pour désactiver temporairement les prédictions routinières.

3. Synthèse du Benchmark

À l'instar des constats relevés sur les meilleures pratiques organisationnelles, l'intégration de l'intelligence artificielle dans l'expérience utilisateur nécessite un cadre structuré. L'analyse des acteurs majeurs (Uber, Airbnb, Trainline/Deutsche Bahn, Google Maps) fait émerger 4 piliers de succès :

1. **Primauté du Contexte Temporel :** L'heure de la journée et le jour de la semaine sont les variables les plus prédictives pour des habitudes de voyage.
2. **Modèles Hybrides :** Les entreprises commencent par une baseline heuristique (règles métier) avant de déployer des modèles de Machine Learning (XGBoost) en production pour garantir une latence très faible ($< 100ms$).
3. **Gestion du "Cold Start" :** Pour les nouveaux utilisateurs sans historique, l'interface doit revenir gracieusement à une barre de recherche standard ou afficher les trajets populaires régionaux.
4. **UX "Zero-Click" :** La prédiction ne sert à rien si elle n'est pas mise en valeur de manière flagrante dans l'interface (Call-to-Action proéminent "Confirmer & Payer").

4. Stratégie de Collecte de Données

La donnée est le moteur de ce projet. Elle sera collectée depuis les bases ONCF et segmentée en quatre catégories :

Catégorie	Features (Variables clés)
Utilisateur (Profil)	ID, gare d'attache (déduite de la gare de départ la plus fréquente dans l'historique), classe préférée, fréquence de voyage (navetteur vs. occasionnel).
Trajets (Item)	Gares O/D, horaire, classe, prix, taux de remplissage, ponctualité historique du train.
Interactions	Historique des réservations (signal fort), recherches non converties (signal d'intention), mises en favoris (signal intermédiaire).
Contexte Temps Réel	Heure d'ouverture de l'app, jour de la semaine, indicateur jour férié/vacances, météo, localisation GPS (transmise par le client mobile à chaque requête, mappée vers la gare la plus proche en temps réel — non stockée en base).

***Note :** Les poids relatifs de chaque signal d'interaction (ex : réservation > favori > recherche non convertie) sont indiqués ici à titre illustratif. Ils seront calibrés par validation croisée lors de la phase d'expérimentation. Il convient de noter qu'une recherche abandonnée n'est pas nécessairement un signal négatif — elle traduit une intention non convertie dont la cause peut être le prix ou l'horaire, et non le trajet lui-même.*

5. Architecture ML et Recommandations Techniques

5.1. Cadrage du Problème : Learning to Rank en Deux Étapes

Ce projet est un problème de **ranking** (classement). Conformément aux architectures déployées par Uber (pool de destinations candidates scoré par XGBoost) et Airbnb (GBDT pour ranker des résultats pré-filtrés), nous adoptons une architecture en deux étapes :

1. **Étape 1 — Candidate Generation (Filtrage) :** Un ensemble restreint de 10 à 20 trajets plausibles est généré via des règles métier déterministes : gare d'attache de l'utilisateur, paires O/D présentes dans son historique récent (30 jours), créneau horaire cohérent avec l'heure d'ouverture de l'app, et disponibilité réelle du train (filtre Hard Constraints).
2. **Étape 2 — Ranking (Scoring ML) :** Les candidats retenus sont scorés par le modèle XGBoost. Chaque trajet reçoit un score de probabilité, et le Top-1 (ou Top-3) est affiché à l'utilisateur sur l'écran d'accueil.

5.2. Le Choix du Modèle : XGBoost (Gradient Boosted Trees)

Nous recommandons fortement **XGBoost** comme modèle de ranking pour l'ONCF car :

- Il excelle sur les données tabulaires structurées (contrairement au Deep Learning pur, souvent surdimensionné pour ce type de données).
- Il offre une grande interprétabilité (Feature Importance) permettant de comprendre et d'expliquer pourquoi un trajet est recommandé.
- La latence d'inférence est minime, essentielle pour un affichage immédiat à l'ouverture de l'app.
- C'est le modèle utilisé en production par Uber pour la prédiction de destination et par Airbnb pour le ranking des résultats de recherche — deux cas d'usage directement transposables.

5.3. Architecture de Déploiement

1. **Offline (Batch)** : Entraînement quotidien du modèle sur les 30 derniers jours de logs transactionnels.
2. **Online (Temps réel)** : L'application mobile fait un appel API contenant l'`user_id`, le `timestamp` et les **coordonnées GPS actuelles**. Le backend (ex : FastAPI) mappe la position vers la gare la plus proche (lookup sur table statique des gares ONCF), interroge le cache (ex : Redis) pour récupérer les *features* utilisateur, génère les candidats (Étape 1), score le pool de trajets candidats avec le modèle XGBoost (Étape 2), et renvoie le Top-1 ou Top-3. *La localisation GPS n'est jamais persistée.*

5.4. Gestion du Model Drift

Un modèle entraîné sur des données historiques voit ses performances se dégrader naturellement au fil du temps (*model drift*). Les habitudes des utilisateurs évoluent (déménagement, changement de poste, nouvelle ligne ferroviaire), et la saisonnalité impacte fortement les patterns de voyage. Pour y remédier :

- **Réentraînement automatique** : Le modèle sera réentraîné quotidiennement (ou hebdomadairement) sur une fenêtre glissante de 30 jours via un pipeline orchestré (Airflow, Prefect).
- **Monitoring continu** : Les métriques seront calculées en continu sur les prédictions de production (comparaison prédiction vs. réservation réelle).
- **Alerting** : Un système d'alerte sera mis en place pour notifier l'équipe si une precision chute sous un seuil critique défini lors de la phase d'expérimentation, déclenchant une investigation et un réentraînement immédiat si nécessaire.

6. Conformité Légale et Protection des Données

Le système traite des données à caractère personnel (historique de réservation, comportement in-app, routines de voyage). Par ailleurs, la localisation GPS est utilisée de manière **éphémère** lors de chaque requête (mapping vers la gare la plus proche en mémoire) sans jamais être persistée en base de données. Au Maroc, ce traitement est encadré par la **Loi 09-08** relative à la protection des personnes physiques à l'égard du traitement des données à caractère personnel, sous le contrôle de la **CNDP** (Commission Nationale de contrôle de la protection des Données à caractère Personnel).

Mesures de conformité prévues :

- **Consentement explicite** : L'utilisateur devra donner son accord explicite pour l'activation du système de recommandation proactif via une option claire dans l'application. Concernant la géolocalisation, le consentement est déjà recueilli par le système d'exploitation mobile (Android/iOS) lors de l'autorisation d'accès à la position ; l'application ONCF ne fait qu'exploiter cette autorisation existante de manière éphémère.
- **Non-stockage de la géolocalisation** : Les coordonnées GPS transmises par le terminal mobile sont utilisées uniquement en mémoire vive lors du traitement de la requête (conversion en gare la plus proche) puis immédiatement supprimées. Aucune donnée de localisation n'est écrite en base de données, dans les logs, ni dans le dataset d'entraînement du modèle.
- **Droit à l'oubli** : Un mécanisme permettra à l'utilisateur de demander la suppression intégrale de son historique de réservation utilisé par le moteur de recommandation.

- **Anonymisation des données d’entraînement** : Les données utilisées pour entraîner le modèle ML seront anonymisées (suppression des identifiants directs, agrégation) afin qu’aucun individu ne puisse être ré-identifié à partir du dataset d’entraînement.
- **Déclaration préalable à la CNDP** : Le traitement sera déclaré auprès de la CNDP conformément aux obligations légales, incluant la finalité du traitement, les catégories de données collectées, et la durée de conservation.
- **Durée de conservation limitée** : Les données comportementales brutes seront conservées pour une durée maximale définie (ex : 12 mois glissants), au-delà de laquelle elles seront purgées ou anonymisées.

7. Faisabilité et Prochaines Étapes

7.1. Réalisabilité :

Le projet MVP peut être réalisé dans un délai réaliste avec une charge de travail maîtrisée. La mise en œuvre est structurée en trois phases logiques : *Première phase (Data Science)* - exploration des données ONCF et entraînement du modèle XGBoost pour atteindre une précision acceptable ; *Deuxième phase (Backend)* - développement d’une API simple et intégration avec l’application mobile ONCF pour l’affichage des recommandations ; *Troisième phase (A/B Testing)* - lancement d’un test A/B réel auprès d’utilisateurs avec collecte de logs et analyse des résultats. L’infrastructure existante d’ONCF (Cloud/Data Lake) est largement suffisante ; aucun nouvel investissement infrastructurel majeur n’est nécessaire.

7.2. Métrique de Succès Prioritaire et Décision :

Le succès du projet sera mesuré via un test A/B standard (Groupe A : barre de recherche classique, Groupe B : recommandation proactive). Les métriques clés sont le *lift de conversion* (réduction du nombre d’étapes avant booking) et la *réduction du temps moyen avant paiement*. Un seuil de déploiement sera défini avant le test : si le *lift* de conversion montre une amélioration mesurable avec une significativité statistique, le système sera déployé progressivement. Les logs seront collectés via des fichiers simples et analysés avec les outils standard de data science. Cette approche garantit une validation empirique basée sur des données réelles d’utilisateurs ONCF, sans dépendre d’hypothèses préalables.

— FIN DU DOCUMENT —